

PROJET NLP

ANALYSE DES OFFRES D'EMPLOI EN DATA

2026-2027

MEMBRES DE L'ÉQUIPE



Mariem Chouchene



Bilel Beyni



Molka Gharbi



Chaima Cherif



Med Akram Bouzaiane



Eya Kassous

PLAN

1- Introduction

2- Compréhension du métier

3- Compréhension et préparation des données

4-Modélisation et évaluation

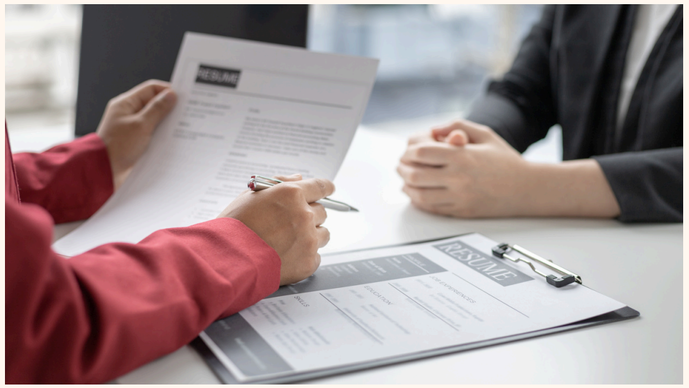
5- Deploiement

6-Conclusion et perspectives



1. INTRODUCTION

1-INTRODUCTION







Problématique : comment exploiter les offres d’emploi Data pour comprendre le marché et relier compétences, postes et entreprises ?



2- COMPRÉHENSION DU MÉTIER

2- COMPRÉHENSION DU MÉTIER

- Les objectifs metier

BO1
Comprendre les tendances du marché

BO2
Classifier automatiquement les postes

BO3
Identifier des familles de postes et de compétences

BO4
Modéliser les relations entre entreprises, postes et compétences

BO5
Prédire les compétences associées à un poste

BO6
Recommander des compétences à acquérir

BO7
Répondre aux questions en langage naturel

2- COMPRÉHENSION DU MÉTIER

- Les objectifs Data science

Objectif métier	Objectif Data Science	Évaluation
BO1 · Tendances du marché	Analyse exploratoire	Fréquences, répartitions
BO2 · Classifier les postes	Classification supervisée	Accuracy, F1 macro
BO3 · Identifier des familles	Clustering K-Means (SBERT)	Silhouette, ARI, NMI
BO4 · Modéliser les relations	Graphe hétérogène + Louvain	Modularité, centralités
BO5 · Prédire les compétences	GNN GraphSAGE (liens)	ROC-AUC, AP
BO6 · Recommander	Fréquence + cooccurrence	Precision@K, Recall@K
BO7 · Répondre aux questions	Graph-RAG simplifié	Vérification des faits



3- COMPRÉHENSION ET PRÉPARATION DES DONNÉES

3- COMPRÉHENSION ET PRÉPARATION DES DONNÉES

- Compréhension des données

785 741

offres dans le dataset

Dataset Hugging Face data_jobs

20 000

offres analysées

Échantillon de 20 000 offres, 12 251 entreprises

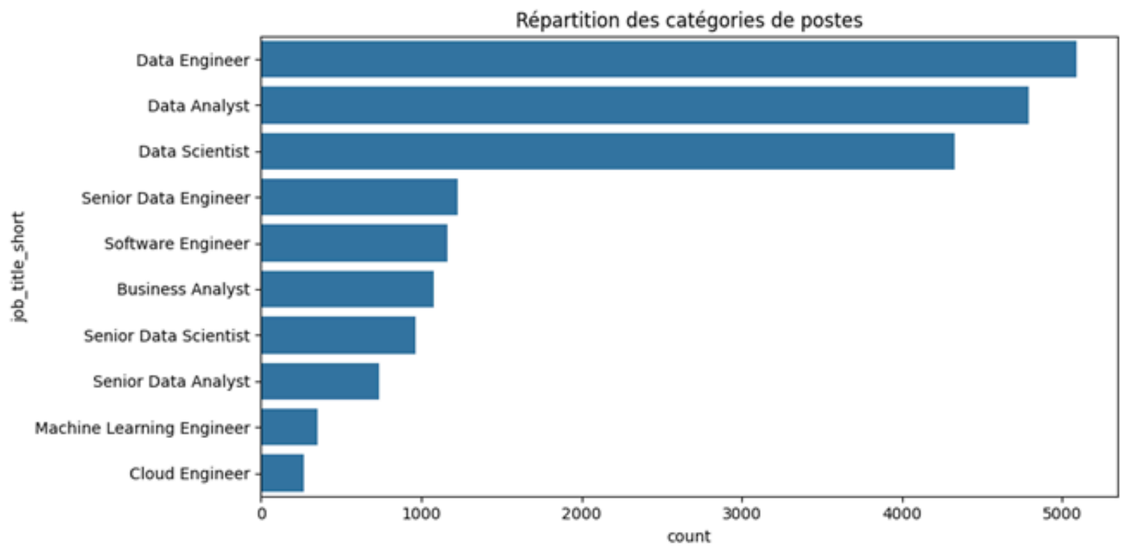
Top 4

compétences clés

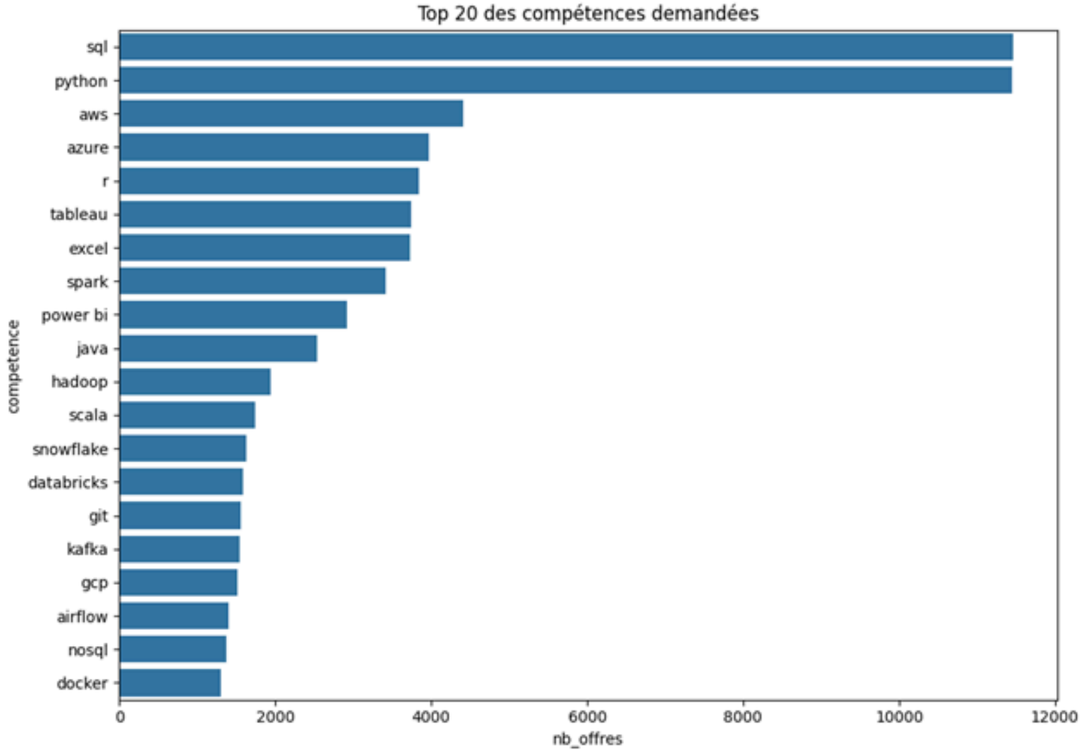
SQL 57 % · Python 57 % · AWS 22 % · Azure 20 %

- **Pays les plus représentés : États-Unis (5 396 offres), Inde, Royaume-Uni, France.**
- **Postes dominants : Data Engineer, Data Analyst, Data Scientist.**

3- COMPRÉHENSION ET PRÉPARATION DES DONNÉES



10 catégories de postes : Data Engineer (5 093), Data Analyst (4 791) et Data Scientist (4 328) dominent.



SQL (57,3 %) et Python (57,3 %) sont les compétences les plus demandées, devant AWS (22,0 %) et Azure (19,9 %).

3- COMPRÉHENSION ET PRÉPARATION DES DONNÉES

-Préparation des données

1 — Sélection

Conservation des colonnes utiles : titre, catégorie, compétences, pays, entreprise, date, salaire.

2 — Valeurs manquantes

Suppression des offres sans titre, sans compétences ou sans entreprise.

3 — Échantillonnage

Tirage aléatoire de 20 000 offres (graine = 42) : mémoire maîtrisée et résultats reproductibles.

4 — Normalisation des compétences

Conversion en listes, minuscules, espaces nettoyés, doublons supprimés.

5 — Nettoyage du texte

Entreprises et titres nettoyés (espaces, casse, ponctuation) : colonne title_clean.

- **Résultat : 20 000 offres exploitables, chacune avec au moins une compétence et une entreprise renseignée.**

3- COMPRÉHENSION ET PRÉPARATION DES DONNÉES

-Préparation pour la modèlisation

Prétraitement des titres (spaCy)

Minuscules, suppression des mots vides et de la ponctuation, lemmatisation.

Représentations construites

TF-IDF sur les titres (unigrammes et bigrammes) ; Word2Vec sur les compétences ; SBERT (all-MiniLM-L6-v2) sur les titres.

Séparation train / test sans fuite

80 / 20 avec GroupShuffleSplit sur les titres identiques ; TF-IDF et Word2Vec ajustés uniquement sur le train.

16 397

offres d'entraînement

3 603

offres de test

10

classes de postes à prédire



4-MODÉLISATION ET ÉVALUATION

4-MODÉLISATION ET ÉVALUATION

- BO1 · Tendances du marché → Analyse exploratoire

MODÈLE / MÉTHODE

Pas de modèle prédictif : analyse exploratoire des 20 000 offres (compétences, pays, évolution mensuelle, salaires par catégorie de poste).

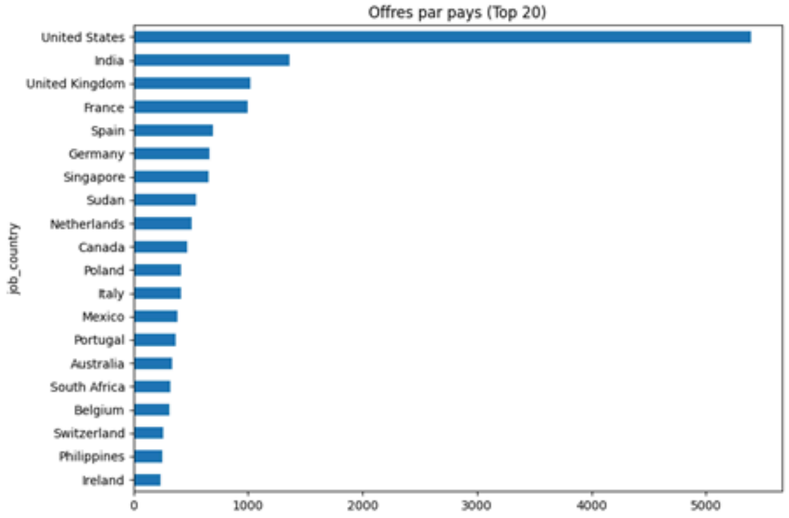
ÉVALUATION

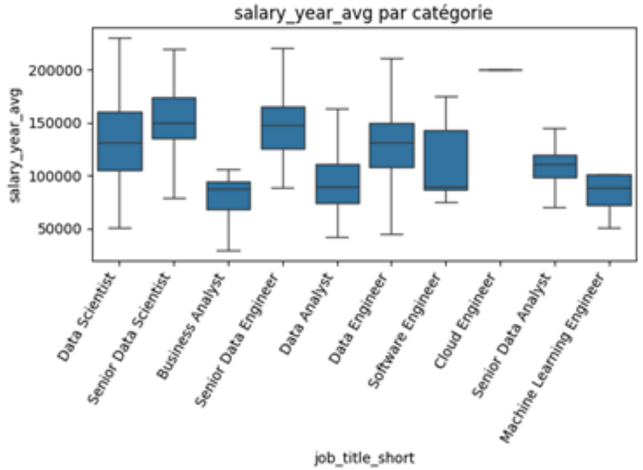
57 %

offres avec SQL ou Python

5 396

offres aux États-Unis (n°1)





SQL/Python très demandés ; États-Unis loin devant l'Inde (1 359) et le Royaume-Uni (1 018). Salaire annuel médian : 150 000 $ (Senior Data Scientist) contre 90 000 $ (Data Analyst).

Lecture : évaluation descriptive (fréquences, répartitions). Salaires disponibles pour peu d'offres (≈ 140-150 par poste principal) : à interpréter avec prudence.

4-MODÉLISATION ET ÉVALUATION

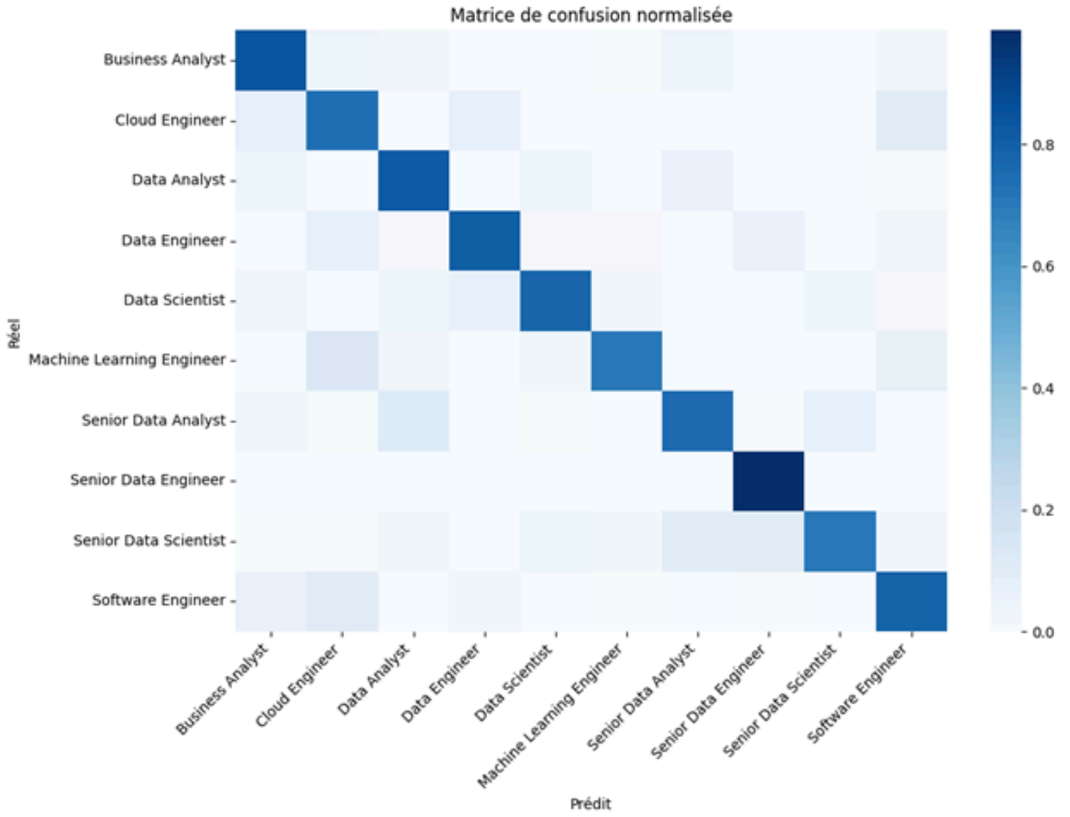
- BO2 · Classifier les postes → Classification supervisée

MODÈLE / MÉTHODE

Régression logistique pour prédire la catégorie de poste (10 classes) à partir du titre. Quatre représentations comparées : TF-IDF, Word2Vec, SBERT, SBERT + Word2Vec. Split 80/20 sans fuite.

ÉVALUATION

Représentation	Accuracy	F1 macro
SBERT titres	0,834	0,739
SBERT + Word2Vec	0,835	0,738
TF-IDF titres	0,841	0,732
Word2Vec compétences	0,286	0,246



Lecture : SBERT retenu (meilleur F1 macro). Senior Data Engineer très bien classé (F1 0,95) ; Cloud Engineer difficile (F1 0,38, 49 offres test).

4-MODÉLISATION ET ÉVALUATION

- BO3 · Identifier des familles → Clustering K-Means (SBERT)

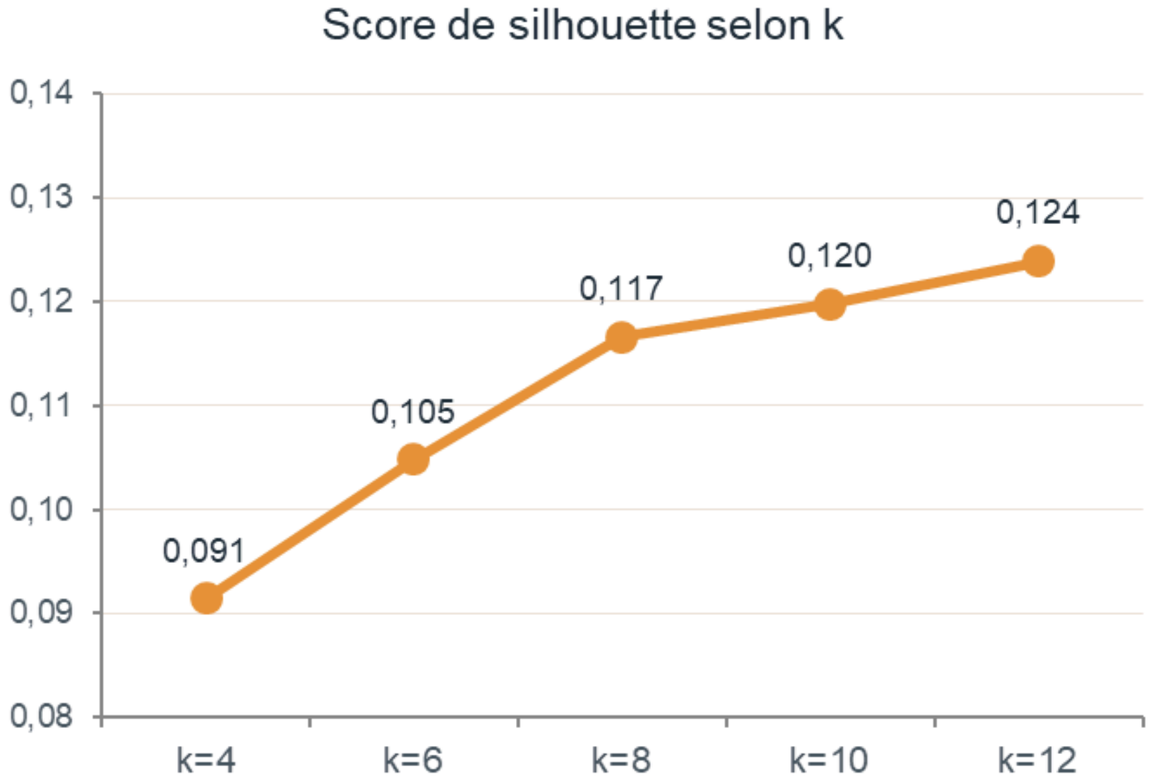
MODÈLE / MÉTHODE

K-Means sur les embeddings SBERT (384 dimensions) des titres, sans utiliser les étiquettes. k testé de 4 à 12, choisi par le score de silhouette : k = 12. Même démarche sur les compétences fréquentes.

ÉVALUATION

0,12	0,38	0,51
Silhouette (k = 12)	**ARI vs catégories**	**NMI vs catégories**

Taille des clusters : de 721 à 2 537 offres.



Lecture : silhouette faible et encore croissante à k = 12 (borne testée) : clusters qui se chevauchent ; ARI/NMI modérés, les familles ne reproduisent que partiellement les catégories.

4-MODÉLISATION ET ÉVALUATION

BO4 · Modéliser les relations → Graphe hétérogène + Louvain

STRUCTURE DU GRAPHE

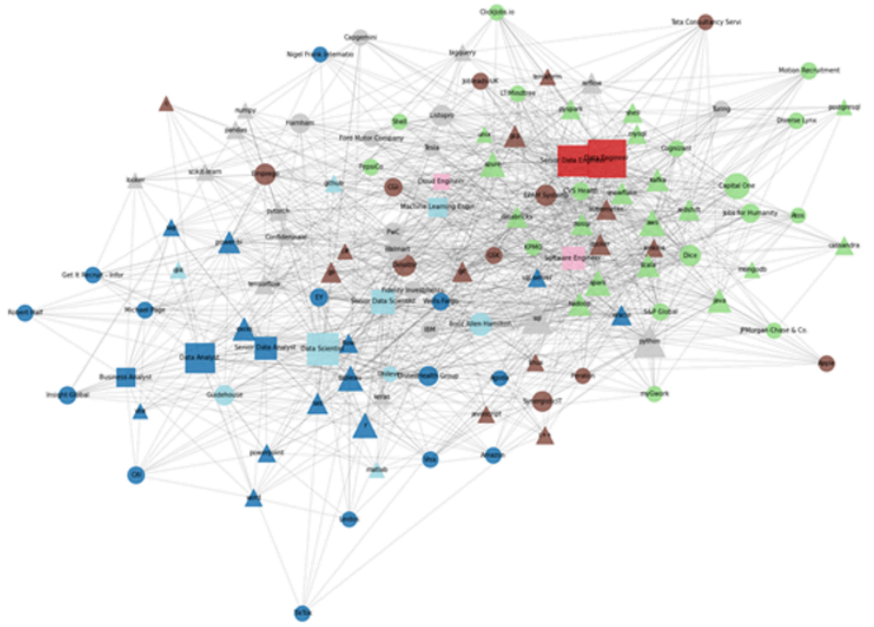
3 types de nœuds · 3 types de relations



PONDÉRATION DES LIENS

Support = nombre d'offres (liens gardés si ≥ 3 offres)

PMI = association plus forte que le hasard : SQL est partout, on garde le spécifique



● Entreprise ■ Poste ▲ Compétence | couleur = communauté

3 272 offres	**220** nœuds	**1 904** arêtes	**0,324** modularité · 5 communautés

Data Engineer
↔ AWS · Spark · Azure

Data Scientist & ML Engineer
↔ Python · TensorFlow

Data Analyst
↔ Tableau · Excel · Power BI

4-MODÉLISATION ET ÉVALUATION

BO5 · Prédire les compétences → GNN GraphSAGE (prédiction de liens)

PRINCIPE DU MODÈLE

Tâche : ce poste et cette compétence sont-ils liés ?

1 Entrée → 2 Voisinage → 3 Score → 4 Sortie

SÉPARATION TRAIN / TEST

Train	180 positifs	180 négatifs
Test	45 positifs	45 négatifs

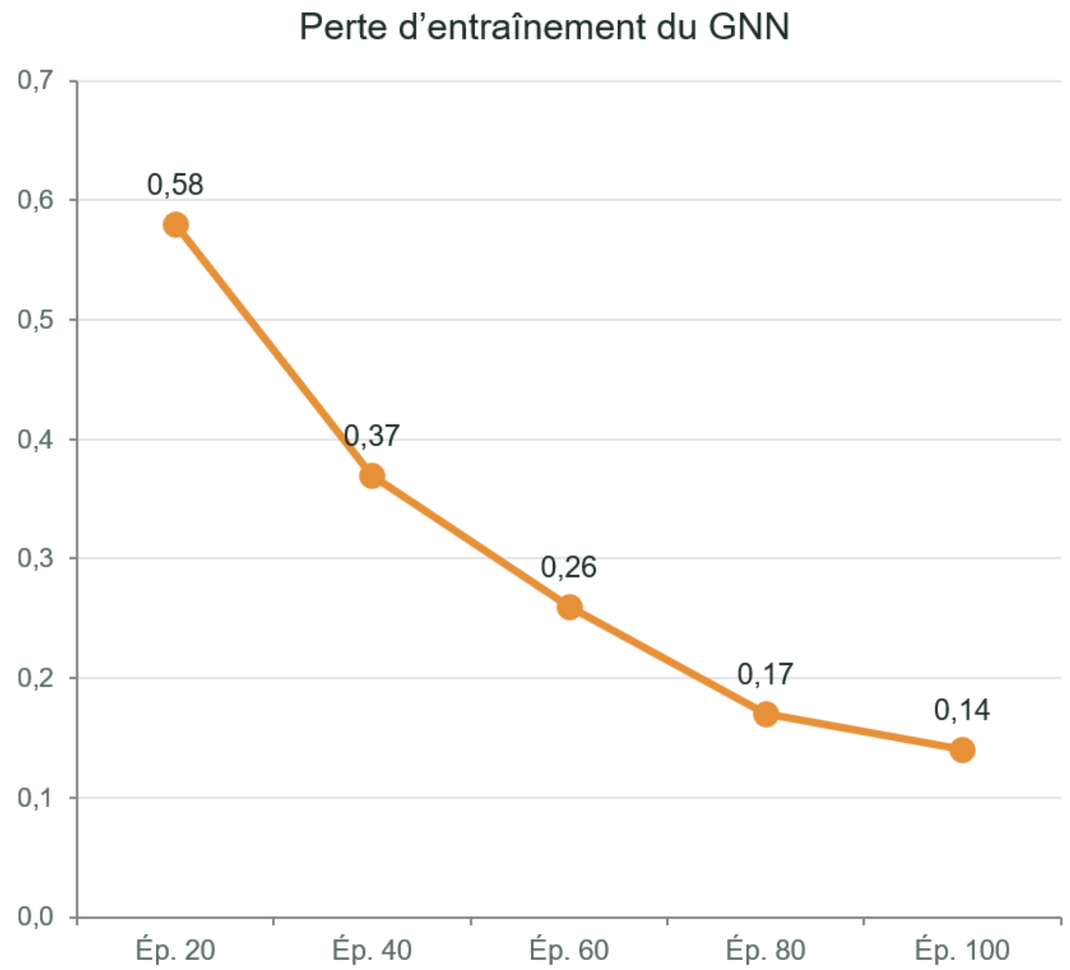
0,907 ROC-AUC

0,926 Average Precision

45 + 45 liens de test

0,14 perte finale (0,58 au départ)

Lecture : AUC 0,91 et perte décroissante : le modèle apprend.



4-MODÉLISATION ET ÉVALUATION

- BO6 · Recommander → Fréquence + cooccurrence

MODÈLE / MÉTHODE

Score = 0,65 × fréquence de la compétence dans la catégorie + 0,35 × cooccurrence avec les compétences déjà possédées. Exemple : Data Engineer maîtrisant Python et SQL.

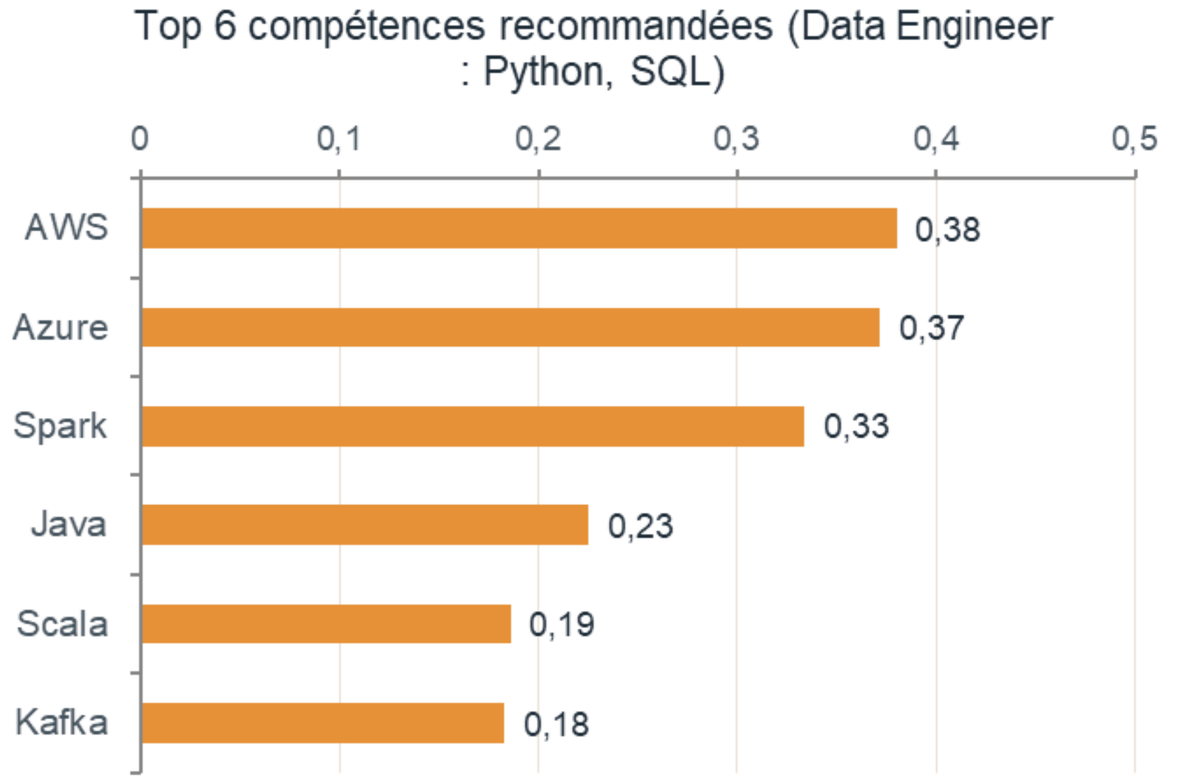
ÉVALUATION

0,65 **Recall@5**

0,13 **Precision@5**

500 **offres évaluées**

Protocole : une compétence masquée par offre, recommandation du top 5.



Lecture : la compétence masquée est retrouvée dans le top 5 près de 2 fois sur 3. Precision@5 plafonnée à 0,20 (1 seule compétence cachée pour 5 propositions).

4-MODÉLISATION ET ÉVALUATION

- BO7 · Répondre aux questions → Graph-RAG simplifié

MODÈLE / MÉTHODE

Détection de l'intention et des entités (compétences, postes, entreprises), puis récupération des faits dans l'index des offres et le graphe. Un LLM local (Ollama) peut reformuler, uniquement à partir de ces faits.

ÉVALUATION

2 / 3

questions de démo répondues

Faits

vérifiables dans les données

Évaluation : vérification des faits (comptages comparables au dataset).

Q1 · Quelles entreprises proposent des postes avec Python et SQL ?

Capital One : 50 offres sur 66 (75,8 %) · Emprego : 58 sur 175 · Deloitte : 29 sur 60

Q2 · Quelles compétences sont demandées pour Data Engineer ?

Python (539 offres) · SQL (521) · AWS (325) · Spark (298) · Azure (291)

Q3 · Quels postes demandent Spark ou Kafka ?

Non traitée : message « entreprise absente du sous-graphe » (limite à corriger)

Lecture : réponses traçables car issues de comptages (le LLM ne fait que reformuler). Limite : la détection d'intention échoue sur certaines questions (Q3).



5- DEPLOIEMENT

5- DÉPLOIEMENT

-Application Streamlit

Entrainement et modelisation des modeles

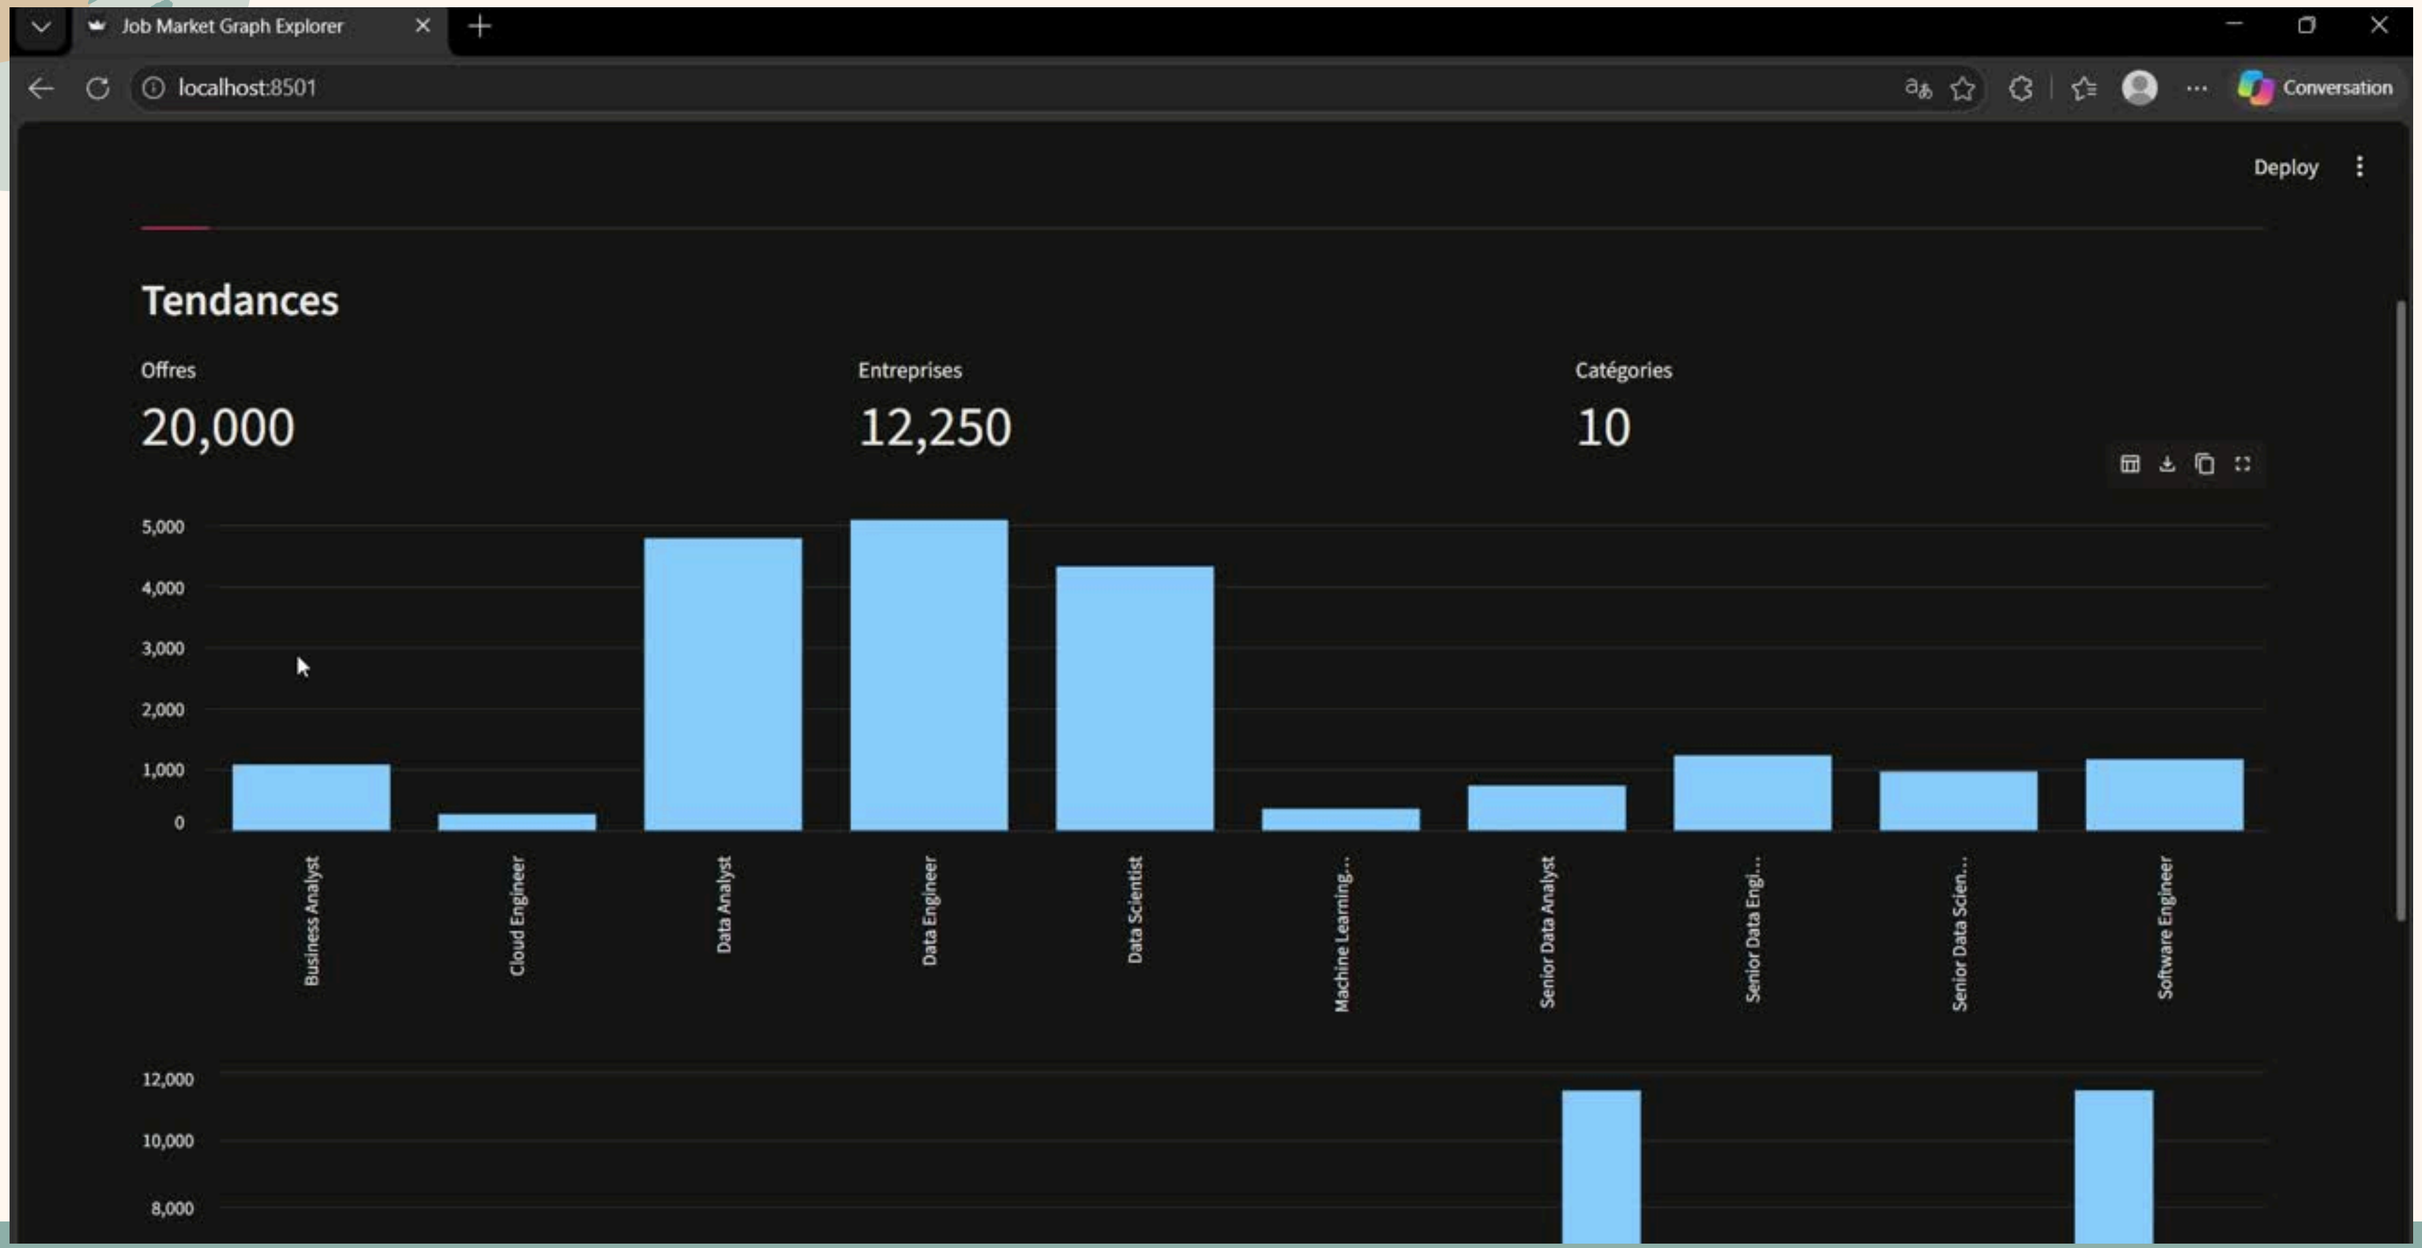
generer les artifactset le app.py

lancer lapp en local

Fonctionnalités

Marché — tendances et indicateurs
Recherche — filtrage par compétences
Graphe — exploration des relations
Q&A — questions-réponses

5- DEMO


Job Market Graph Explorer
localhost:8501
Conversation
Deploy
Tendances
Offres
20,000
Entreprises
12,250
Catégories
10
5,000
4,000
3,000
2,000
1,000
0
Business Analyst
Cloud Engineer
Data Analyst
Data Engineer
Data Scientist
Machine Learning...
Senior Data Analyst
Senior Data Engi...
Senior Data Scien...
Software Engineer
12,000
10,000
8,000



8- CONCLUSION ET PERSPECTIVES

MERCI POUR VOTRE ATTENTION

